



Uniwersytet
Ekonomiczny
w Katowicach



blisko

międzynarodowo



przez całe życie

LOGIKA DLA INFORMATYKÓW

Zbiory przybliżone

dr hab. Ewa Michalska

Zbiory przybliżone



Zdzisław Pawlak (1926-2006)
polski matematyk, informatyk
twórca teorii zbiorów przybliżonych
sformułowanej w 1982 roku
(stanowiącej rozwinięcie klasycznej
teorii zbiorów). Teoria zbiorów
przybliżonych jest metodą analizy
danych.

- Porównując dwa dowolne obiekty (nawet jeśli są bardzo podobne) zawsze możemy znaleźć między nimi różnice, zwłaszcza jeśli uwzględnimy dostatecznie dużo cech (atrybutów), z dostatecznie dużą dokładnością.
- Jeśli zmniejszymy dokładność opisu (ograniczymy się np. tylko do cech istotnych dla danego zastosowania), wówczas obiekty wcześniej rozróżnialne staną się nierozróżnialne.
- Zbiory przybliżone powstały (po odrzuceniu wymogu istnienia ściśle określonych granic) jako zbiory definiowane za pomocą dolnego i górnego przybliżenia zbioru.

Teorie zbiorów

- W klasycznej teorii zbiorów (teorii mnogości), zbiór jest definiowany przez swoje elementy, nie jest potrzebna żadna dodatkowa wiedza o elementach uniwersum, z których tworzymy zbiór.
- W teorii zbiorów przybliżonych (*rough set theory*), zakładamy, że mamy pewne informacje o elementach uniwersum i dane te są wykorzystywane do tworzenia zbiorów.
- W teorii zbiorów rozmytych (*fuzzy set theory*), elementy mogą należeć do zbioru w pewnym stopniu, a nie definitywnie jak ma to miejsce w klasycznej teorii zbiorów.

Teoria zbiorów przybliżonych

- Elementy, o których mamy identyczną informację są podobne i tworzą tzw. **zbiory elementarne**, stanowiące podstawę rozumowań w teorii zbiorów przybliżonych.
- Suma dowolnych zbiorów elementarnych jest nazywana **zbiorem definiowalnym**.
- Zbiory, które nie są zbiorami definiowalnymi nazywamy **zbiorami przybliżonymi**.

UWAGA:


Zbiorów przybliżonych nie można jednoznacznie scharakteryzować przez własności ich elementów. Dlatego w teorii zbiorów przybliżonych wprowadza się pojęcia dolnego i górnego przybliżenia zbioru, które pozwalają każdy zbiór niedefiniowalny (przybliżony) scharakteryzować za pomocą dwóch zbiorów definiowalnych – dolnego i górnego przybliżenia.



Teoria zbiorów przybliżonych

- **Dolnym przybliżeniem zbioru** są wszystkie elementy, które (w świetle posiadanej wiedzy) mogą być jednoznacznie zaklasyfikowane do rozważanego zbioru.
- **Górnym przybliżeniem zbioru** są wszystkie elementy, które (w świetle posiadanej wiedzy) nie mogą być wykluczone jako elementy rozważanego zbioru.
- Różnica między górnym a dolnym przybliżeniem jest nazywana **obszarem brzegowym** (brzegiem) zbioru.

Dany zbiór jest zbiorem przybliżonym wtedy i tylko wtedy, gdy jego obszar brzegowy jest niepusty.



Główne rodzaje wnioskowania

Wnioskowanie dedukcyjne – wnioskowanie dedukcyjne daje narzędzia służące do wyprowadzania zdań prawdziwych z innych zdań prawdziwych. Wnioskowanie dedukcyjne prowadzi zawsze do konkluzji prawdziwych. Wnioskowanie to jest stosowane w rozumowaniach na gruncie matematyki czy logiki. Rozstrzygania prawdziwości hipotez dokonuje się drogą formalnego rozumowania.

Wnioskowanie indukcyjne – punktem wyjścia do tego typu rozumowań są pewne fakty częściowe o badanej rzeczywistości (przykłady), które są następnie uogólniane, tworząc wiedzę o szerszym świecie, niż ten który stanowił punkt wyjścia wnioskowania. Wnioskowanie indukcyjne nie prowadzi do wniosków prawdziwych, a jedynie do wniosków prawdopodobnych (możliwych). Rozstrzygania prawdziwości hipotez dokonuje się na podstawie eksperymentu (np. w fizyce).

Główne cechy wnioskowania

Wnioskowanie dedukcyjne:

- zastosowania: matematyka, logika
- pełna teoria
- wnioskowanie zawsze prawdziwe
- weryfikacja hipotez – dowód

Wnioskowanie indukcyjne:

- zastosowania: nauki przyrodnicze i techniczne
- częściowe teorie
- wnioski prawdopodobne (możliwe)
- weryfikacja hipotez – eksperyment

Teoria zbiorów przybliżonych a praktyka

Wykorzystanie zbiorów przybliżonych w analizie danych umożliwia:

- szukanie zależności między danymi
- redukcję danych
- określenie wag danych
- generowanie reguł decyzyjnych z danych

Zastosowania:

- teoria decyzji
- bazy danych
- medycyna
- farmakologia
- bankowość
- lingwistyka
- ekonomia
- teoria sterowania
- teoria konfliktów
- ochrona środowiska



Zbiory przybliżone w analizie danych

System informacyjny jest sposobem przedstawiania informacji o obiektach charakteryzowanych przez ten sam zbiór cech

Systemem informacyjnym nazywamy uporządkowaną czwórkę $SI = \langle U, Q, V, f \rangle$

gdzie:

U – niepusty, skończony zbiór obiektów,

Q – zbiór wybranych cech (atrybutów) obiektów ze zbioru U

V – zbiór wszystkich możliwych wartości rozważanych cech

f – funkcja informacyjna, $f: U \times Q \rightarrow V$

Ponadto:

x – obiekt zbioru U

q – cecha obiektu x

$v_q^x = f(x, q)$ to wartość cechy q obiektu x

V_q – zbiór wszystkich możliwych wartości cechy q

$f(x, q) \in V_q$

$$V = \bigcup_{q \in Q} V_q$$



Tablica decyzyjna

Tablicą decyzyjną nazywamy uporządkowaną piątkę $DT = \langle U, C, D, V, f \rangle$

gdzie:

U – niepusty, skończony zbiór obiektów,

C – zbiór cech (atrybutów) warunkowych

D – zbiór cech (atrybutów) decyzyjnych

V – zbiór wszystkich możliwych wartości rozważanych cech

f – funkcja informacyjna

$C \cup D = Q$

Przykład 1: Przykład systemu informacyjnego

Wiersze opisują pacjentów, a kolumny tabeli reprezentują symptomy choroby (gorączka, kaszel, zmęczenie, utrata smaku lub węchu). Ostatnia kolumna definiuje podział pacjentów na dwie klasy: chorujących na COVID i niechorujących na COVID.

Pacjent (U)	gorączka (q ₁)	kaszel (q ₂)	zmęczenie (q ₃)	utrata smaku lub węchu (q ₄)	COVID (q ₅)
1	Nie	Tak	Tak	Tak	Tak
2	Tak	Nie	Tak	Nie	Tak
3	Nie	Nie	Tak	Nie	Nie
4	Nie	Tak	Nie	Tak	Tak
5	Tak	Nie	Tak	Nie	Nie
6	Tak	Tak	Nie	Tak	Tak

Przykład 1 c.d.:

Problem: Znaleźć zależność pomiędzy występowaniem COVID (lub niewystępowaniem) – atrybut decyzyjny, a symptomami opisującymi pacjentów – atrybuty warunkowe. Opisać zbiór przypadków $\{1,2,4,6\}$ (lub zbiór $\{3,5\}$) w kategoriach wartości atrybutów warunkowych.

Pacjent (U)	gorączka ($c_1=q_1$)	kaszel ($c_2=q_2$)	zmęczenie ($c_3=q_3$)	utrata smaku lub węchu ($c_4=q_4$)	COVID ($d_1=q_5$)
1	Nie	Tak	Tak	Tak	Tak
2	Tak	Nie	Tak	Nie	Tak
3	Nie	Nie	Tak	Nie	Nie
4	Nie	Tak	Nie	Tak	Tak
5	Tak	Nie	Tak	Nie	Nie
6	Tak	Tak	Nie	Tak	Tak

Podział zbioru $Q=\{q_1,q_2,q_3,q_4,q_5\}$ na:

- atrybuty warunkowe $C=\{c_1,c_2,c_3,c_4\}=\{q_1,q_2,q_3,q_4\}$
- atrybuty decyzyjne $D=\{d_1\}=\{q_5\}$



Przykład 1 c.d.:

Analizowane dane nie są spójne ponieważ przypadki 2 i 5 dostarczają sprzecznych informacji, obaj pacjenci są opisani tymi samymi wartościami atrybutów warunkowych, ale są przydzieleni do różnych klas decyzyjnych. Zatem zbiór pacjentów chorujących na COVID nie może być jednoznacznie opisany w kategoriach {gorączka, kaszel, zmęczenie, utrata smaku lub węchu}.

Można jednak opisać ten zbiór w sposób przybliżony:

- $\{1,4,6\}$ jest maksymalnym zbiorem przypadków, które są **z pewnością** zaklasyfikowane do klasy pacjentów chorujących na COVID – dolne przybliżenie
- $\{1,2,4,5,6\}$ jest zbiorem przypadków, co do których **możliwe** jest ich przydzielenie do klasy pacjentów chorujących na COVID (nie można ich wykluczyć) – górne przybliżenie
- $\{2,5\}$ jest zbiorem przypadków, które nie mogą być jednoznacznie przydzielone do klasy COVID lub brak COVID, ze względu na sprzeczny opis atrybutów warunkowych – obszar brzegowy.



Obiekty **P-nierozróżnialne**

Jeśli pewne dwa obiekty $x_a, x_b \in U$ mają takie same wartości wszystkich cech q należących do zbioru $P \subseteq Q$, co możemy zapisać:

$$\forall_{q \in P} f(x_a, q) = f(x_b, q) \quad (\text{lub inaczej } \forall_{q \in P} f_{x_a}(q) = f_{x_b}(q))$$

to mówimy, że obiekty te są **P-nierozróżnialne** lub, że są ze sobą w relacji **P-nierozróżnialności** ($x_a \tilde{P} x_b$)

gdzie:

U – niepusty, skończony zbiór obiektów,

x – obiekt ze zbioru U

Q – zbiór cech (atrybutów) obiektów ze zbioru U

q – cecha obiektu x

P – podzbiór zbioru cech (atrybutów) obiektów ze zbioru U , $P \subseteq Q$

f – funkcja informacyjna, $f: U \times Q \rightarrow V$

V – zbiór wszystkich możliwych wartości cech

Relacja P-nierozróżnialności

Relacją P-nierozróżnialności nazywamy relację \tilde{P} określoną na przestrzeni $U \times U$, spełniającą zależność:

$$x_a \tilde{P} x_b \leftrightarrow \forall_{q \in P} f_{x_a}(q) = f_{x_b}(q)$$

w której $x_a, x_b \in U$ oraz $P \subseteq Q$.

UWAGA:

Relacja \tilde{P} jest zwrotna, symetryczna i przechodnia, jest więc relacją równoważności. Relacja równoważności dzieli zbiór, w którym jest określona, na rodzinę rozłącznych podzbiorów - klas abstrakcji tej relacji.

Klasą abstrakcji relacji \tilde{P} w przestrzeni U nazywamy zbiór wszystkich obiektów $x \in U$ będących w relacji \tilde{P} . Dla każdego $x_a \in U$ istnieje dokładnie jeden taki zbiór:

$$[x_a]_{\tilde{P}} = \{x : x_a \tilde{P} x\}.$$

Rodzinę wszystkich klas abstrakcji relacji \tilde{P} w przestrzeni U , nazywamy **zbiorem ilorazowym** i oznaczamy symbolem U/\tilde{P} .

Aproksymacja (przybliżenie) zbioru

\tilde{P} - dolną aproksymacją zbioru $X \subseteq U$ nazywamy zbiór $\tilde{P}X$ zdefiniowany następująco:

$$\tilde{P}X = \{x \in U: [x]_{\tilde{P}} \subseteq X\}$$

UWAGA:

Dolną aproksymacją zbioru X jest więc zbiór tych obiektów $x \in U$, o których na podstawie wartości cech P możemy z całą pewnością powiedzieć, że są elementami zbioru X . Inaczej, obiekt $x \in U$ jest elementem dolnej aproksymacji, jeżeli cała klasa abstrakcji, do której on należy, jest podzbiorem zbioru X .

\bar{P} - górną aproksymacją zbioru $X \subseteq U$ nazywamy zbiór $\bar{P}X$ zdefiniowany następująco:

$$\bar{P}X = \{x \in U: [x]_{\bar{P}} \cap X \neq \emptyset\}$$

UWAGA:

Górną aproksymacją zbioru X jest więc zbiór tych obiektów $x \in U$, o których na podstawie wartości cech P nie możemy z całą pewnością powiedzieć, że nie są elementami zbioru X . Inaczej, obiekt $x \in U$ jest elementem górnej aproksymacji, jeżeli klasa abstrakcji, do której on należy, ma niepustą część wspólną ze zbiorem X .

Aproksymacja (przybliżenie) zbioru

\tilde{P} - **pozytywny obszar zbioru** $X \subseteq U$ jest tożsamy z jego dolną aproksymacją

$$\text{Pos}_{\tilde{P}}(X) = \tilde{P}X$$

\tilde{P} - **negatywny obszar zbioru** $X \subseteq U$ jest różnicą zbioru U i górnej aproksymacji zbioru X

$$\text{Neg}_{\tilde{P}}(X) = U \setminus \tilde{\tilde{P}}X$$

\tilde{P} - **brzegowy obszar zbioru** $X \subseteq U$ jest różnicą górnej aproksymacji zbioru X i dolnej aproksymacji zbioru X

$$\text{Bn}_{\tilde{P}}(X) = \tilde{\tilde{P}}X \setminus \tilde{P}X$$



Aproksymacja (przybliżenie) zbioru

Zbiór $X \subseteq U$ nazywamy \tilde{P} - **dokładnym** jeśli zachodzi równość jego dolnej i górnej aproksymacji

$$\overline{\tilde{P}}X = \underline{\tilde{P}}X$$

lub \tilde{P} - **przybliżonym** w przeciwnym razie

$$\overline{\tilde{P}}X \neq \underline{\tilde{P}}X$$

Wartość wyrażoną wzorem:

$$\mu_{\tilde{P}}(X) = \frac{\overline{\tilde{P}}X}{\underline{\tilde{P}}X}$$

nazywamy \tilde{P} - **dokładnością** aproksymacji zbioru X .

UWAGA:

Symbolem \bar{A} oznaczamy miarę zbioru A . W przypadku zbiorów skończonych jako miarę możemy przyjąć moc zbioru, w przypadku zbiorów ciągłych – długość przedziału, pole powierzchni, objętość itd..

Aproksymacja (przybliżenie) zbioru

Zbiór $X \subseteq U$ nazywamy:

(a) w przybliżeniu \tilde{P} - **definiowalnym**, jeżeli

$$\underline{\tilde{P}}X \neq \emptyset$$

$$\overline{\tilde{P}}X \neq U$$

(b) w przybliżeniu \tilde{P} - **niedefiniowalnym**, jeżeli

$$\underline{\tilde{P}}X = \emptyset$$

$$\overline{\tilde{P}}X \neq U$$

(c) zewnętrznie \tilde{P} - **niedefiniowalnym**, jeżeli

$$\underline{\tilde{P}}X \neq \emptyset$$

$$\overline{\tilde{P}}X = U$$

(d) całkowicie \tilde{P} - **niedefiniowalnym**, jeżeli

$$\underline{\tilde{P}}X = \emptyset$$

$$\overline{\tilde{P}}X = U$$



Przykład 2:

Dana jest tablica zawierająca informacje odnotowane przez właściciela komis samochodowego

obiekt (U)	liczba drzwi (q_1)	moc silnika (q_2)	kolor (q_3)	marka (q_4)
x_1	2	60	niebieski	Toyota
x_2	2	100	czarny	Nissan
x_3	2	200	czarny	Ferrari
x_4	2	200	czerwony	Ferrari
x_5	2	200	czerwony	Toyota
x_6	3	100	czerwony	Toyota
x_7	3	100	czerwony	Toyota
x_8	3	200	czarny	Ferrari
x_9	4	100	niebieski	Nissan
x_{10}	4	100	niebieski	Nissan

Dziedziny cech (zbiór wartości funkcji informacyjnych):

$V_{q_1} = \{2, 3, 4\}$, $V_{q_2} = \{60, 100, 200\}$, $V_{q_3} = \{\text{czarny}, \text{niebieski}, \text{czerwony}\}$,
 $V_{q_4} = \{\text{Ferrari}, \text{Nissan}, \text{Toyota}\}$

Przykład 2:

Wykorzystując tablice decyzyjną, stworzymy system ekspertowy, który na podstawie informacji o liczbie drzwi, mocy silnika i kolorze samochodu określi jego markę

Reguła (R)	liczba drzwi ($c_1=q_1$)	moc silnika ($c_2=q_2$)	kolor ($c_3=q_3$)	marka ($d_1=q_4$)
1	2	60	niebieski	Toyota
2	2	100	czarny	Nissan
3	2	200	czarny	Ferrari
4	2	200	czerwony	Ferrari
5	2	200	czerwony	Toyota
6	3	100	czerwony	Toyota
7	3	100	czerwony	Toyota
8	3	200	czarny	Ferrari
9	4	100	niebieski	Nissan
10	4	100	niebieski	Nissan



Przykład 2 c.d.:

Uniwersum $U = \{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_8, x_9, x_{10}\}$

Podział zbioru $Q = \{q_1, q_2, q_3, q_4\}$ na:

- atrybuty warunkowe

$C = \{c_1, c_2, c_3\} = \{q_1, q_2, q_3\} = \{\text{liczba drzwi, moc silnika, kolor}\}$

- atrybuty decyzyjne

$D = \{d_1\} = \{q_4\} = \{\text{marka}\}$

Treść zawartą w tablicy decyzyjnej można przedstawić w postaci reguł:

R1: JEŻLI $c_1=2$ I $c_2=60$ I $c_3=\text{niebieski}$ TO $d_1=\text{Toyota}$

R2: JEŻLI $c_1=2$ I $c_2=100$ I $c_3=\text{czarny}$ TO $d_1=\text{Nissan}$

R3: JEŻLI $c_1=2$ I $c_2=200$ I $c_3=\text{czarny}$ TO $d_1=\text{Ferrari}$

R4: JEŻLI $c_1=2$ I $c_2=200$ I $c_3=\text{czerwony}$ TO $d_1=\text{Ferrari}$

R5: JEŻLI $c_1=2$ I $c_2=200$ I $c_3=\text{czerwony}$ TO $d_1=\text{Toyota}$

R6: JEŻLI $c_1=3$ I $c_2=100$ I $c_3=\text{czerwony}$ TO $d_1=\text{Toyota}$

R7: JEŻLI $c_1=3$ I $c_2=100$ I $c_3=\text{czerwony}$ TO $d_1=\text{Toyota}$

R8: JEŻLI $c_1=3$ I $c_2=200$ I $c_3=\text{czarny}$ TO $d_1=\text{Ferrari}$

R9: JEŻLI $c_1=4$ I $c_2=100$ I $c_3=\text{niebieski}$ TO $d_1=\text{Nissan}$

R10: JEŻLI $c_1=4$ I $c_2=100$ I $c_3=\text{niebieski}$ TO $d_1=\text{Nissan}$



Przykład 2 c.d.:

Klasy abstrakcji relacji C-nierozróżnialności \tilde{C} określonej przez zbiór cech C

$$[x_1]_{\tilde{C}} = \{x_1\}$$

$$[x_2]_{\tilde{C}} = \{x_2\}$$

$$[x_3]_{\tilde{C}} = \{x_3\}$$

$$[x_4]_{\tilde{C}} = [x_5]_{\tilde{C}} = \{x_4, x_5\}$$

$$[x_6]_{\tilde{C}} = [x_7]_{\tilde{C}} = \{x_6, x_7\}$$

$$[x_8]_{\tilde{C}} = \{x_8\}$$

$$[x_9]_{\tilde{C}} = [x_{10}]_{\tilde{C}} = \{x_9, x_{10}\}$$

pary obiektów w zbiorach $\{x_4, x_5\}, \{x_6, x_7\}, \{x_9, x_{10}\}$ są C-nierozróżnialne

Zbiór ilorazowy:

$$U/\tilde{C} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4, x_5\}, \{x_6, x_7\}, \{x_8\}, \{x_9, x_{10}\}\}$$



Przykład 2 c.d.:

W przestrzeni U istnieją trzy zbiory samochodów:

$$\begin{aligned}X_F &= \{x_3, x_4, x_8\} \\ X_N &= \{x_2, x_9, x_{10}\} \\ X_T &= \{x_1, x_5, x_6, x_7\}\end{aligned}$$

Dolne aproksymacje zbiorów X_F , X_N , X_T :

$$\begin{aligned}\underline{\tilde{C}}X_F &= \{x_3\} \cup \{x_8\} = \{x_3, x_8\} \\ \underline{\tilde{C}}X_N &= \{x_2\} \cup \{x_9, x_{10}\} = \{x_2, x_9, x_{10}\} \\ \underline{\tilde{C}}X_T &= \{x_1\} \cup \{x_6, x_7\} = \{x_1, x_6, x_7\}\end{aligned}$$

Obiekt $x \in U$ jest elementem dolnej aproksymacji, jeżeli cała klasa abstrakcji, do której on należy, jest podzbiorem zbioru X

Górne aproksymacje zbiorów X_F , X_N , X_T :

$$\begin{aligned}\bar{\tilde{C}}X_F &= \{x_3\} \cup \{x_4, x_5\} \cup \{x_8\} = \{x_3, x_4, x_5, x_8\} \\ \bar{\tilde{C}}X_N &= \{x_2\} \cup \{x_9, x_{10}\} = \{x_2, x_9, x_{10}\} \\ \bar{\tilde{C}}X_T &= \{x_1\} \cup \{x_4, x_5\} \cup \{x_6, x_7\} = \{x_1, x_4, x_5, x_6, x_7\}\end{aligned}$$

Obiekt $x \in U$ jest elementem górnej aproksymacji, jeżeli klasa abstrakcji, do której on należy, ma niepustą część wspólną ze zbiorem X

Przykład 2 c.d.:

Obszar brzegowy zbiorów X_F , X_N , X_T :

$$\text{Bn}_{\tilde{C}}(X_F) = \bar{\tilde{C}}X_F \setminus \tilde{C}X_F = \{x_3, x_4, x_5, x_8\} \setminus \{x_3, x_8\} = \{x_4, x_5\}$$

$$\text{Bn}_{\tilde{C}}(X_N) = \bar{\tilde{C}}X_N \setminus \tilde{C}X_N = \{x_2, x_9, x_{10}\} \setminus \{x_2, x_9, x_{10}\} = \emptyset$$

$$\text{Bn}_{\tilde{C}}(X_T) = \bar{\tilde{C}}X_T \setminus \tilde{C}X_T = \{x_1, x_4, x_5, x_6, x_7\} \setminus \{x_1, x_6, x_7\} = \{x_4, x_5\}$$

Obszar pozytywny zbiorów X_F , X_N , X_T :

$$\text{Pos}_{\tilde{C}}(X_F) = \tilde{C}X_F = \{x_3, x_8\}$$

$$\text{Pos}_{\tilde{C}}(X_N) = \tilde{C}X_N = \{x_2, x_9, x_{10}\}$$

$$\text{Pos}_{\tilde{C}}(X_T) = \tilde{C}X_T = \{x_1, x_6, x_7\}$$

Obszar negatywny zbiorów X_F , X_N , X_T :

$$\text{Neg}_{\tilde{C}}(X_F) = U \setminus \bar{\tilde{C}}X_F = \{x_1, x_2, x_6, x_7, x_9, x_{10}\}$$

$$\text{Neg}_{\tilde{C}}(X_N) = U \setminus \bar{\tilde{C}}X_N = \{x_1, x_3, x_4, x_5, x_6, x_7, x_8\}$$

$$\text{Neg}_{\tilde{C}}(X_T) = U \setminus \bar{\tilde{C}}X_T = \{x_2, x_3, x_8, x_9, x_{10}\}$$



Przykład 2 c.d.:

Dokładność aproksymacji zbiorów X_F , X_N , X_T :

$$\mu_{\tilde{C}}(X_F) = \frac{\overline{\tilde{C}X_F}}{\underline{\tilde{C}X_F}} = \frac{2}{4} = 0,5$$

$$\mu_{\tilde{C}}(X_N) = \frac{\overline{\tilde{C}X_N}}{\underline{\tilde{C}X_N}} = \frac{3}{3} = 1$$

$$\mu_{\tilde{C}}(X_T) = \frac{\overline{\tilde{C}X_T}}{\underline{\tilde{C}X_T}} = \frac{3}{5} = 0,6$$

Dokładność aproksymacji zbioru X_N wynosi 1, co potwierdza fakt, że jest on \tilde{C} - dokładny, czyli jednoznacznie zdefiniowany przez cechy należące do zbioru C .

Przykład 3:

Uniwersum $U = [0; 10)$, $x \in U$

Zbiór cech $Q = \{q_1, q_2\}$, gdzie:

q_1 – część całkowita liczby x (cecha, funkcja podłoga, całość liczby x : $\lfloor x \rfloor$)

q_2 – część ułamkowa liczby x (mantysa liczby x : $x - \lfloor x \rfloor$)

stąd $x = q_1 + q_2$

Funkcje informacyjne:

$$f(x, q_1) = f_x(q_1) = \lfloor x \rfloor$$

$$f(x, q_2) = f_x(q_2) = x - \lfloor x \rfloor$$

Dziedziny cech (zbiór wartości funkcji informacyjnych):

$$V_{q_1} = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}, V_{q_2} = [0, 1)$$



Przykład 3 c.d.:

Klasy abstrakcji:

a) w zbiorze cech $Q=\{q_1, q_2\}$ wszystkie obiekty są rozróżnialne, istnieje zatem nieskończenie wiele jednoelementowych klas abstrakcji relacji **Q-nierozróżnialności** i każdy element U tworzy własną klasę

b) w zbiorach $P_1=\{q_1\}$, $P_2=\{q_2\}$

- dla relacji **P1-nierozróżnialności** mamy 10 klas abstrakcji

$$[0]_{\tilde{P}_1} = [0; 1)$$

$$[1]_{\tilde{P}_1} = [1; 2)$$

$$[2]_{\tilde{P}_1} = [2; 3)$$

...

$$[9]_{\tilde{P}_1} = [9; 10)$$

- dla relacji **P2-nierozróżnialności** mamy nieskończenie wiele dziesięcioelementowych klas abstrakcji, są to zbiory liczb z przestrzeni U o takiej samej części ułamkowej np.:

$$[0,6]_{\tilde{P}_2} = \{0,6; 1,6; 2,6; 3,6; 4,6; 5,6; 6,6; 7,6; 8,6; 9,6\}$$

Zbiory ilorazowe relacji \tilde{P}_1 i \tilde{P}_2 :

$$U/\tilde{P}_1 = \{[0;1); [1;2); [2;3); [3;4); [4;5); [5;6); [6;7); [7;8); [8;9); [9;10)\}$$

U/\tilde{P}_2 - zbiór wszystkich klas abstrakcji

Przykład 3 c.d.:

W przestrzeni U wyodrębnijmy pewien zbiór X w postaci przedziału:
 $X=[1,25; 6,78]$

Dolne aproksymacje zbioru X względem relacji \widetilde{P}_1 i \widetilde{P}_2 :

$$\underline{\widetilde{P}_1}X=[2]_{P_1}\cup[3]_{P_1}\cup[4]_{P_1}\cup[5]_{P_1}=[2;6)$$

$$\underline{\widetilde{P}_2}X=\emptyset$$

Obiekt $x\in U$ jest elementem dolnej aproksymacji, jeżeli cała klasa abstrakcji, do której on należy jest podzbiorem zbioru X

Górne aproksymacje zbioru X względem relacji \widetilde{P}_1 i \widetilde{P}_2 :

$$\overline{\widetilde{P}_1}X=[1]_{P_1}\cup[2]_{P_1}\cup[3]_{P_1}\cup[4]_{P_1}\cup[5]_{P_1}\cup[6]_{P_1}=[1;7)$$

$$\overline{\widetilde{P}_2}X=U$$

Obiekt $x\in U$ jest elementem górnej aproksymacji, jeżeli klasa abstrakcji, do której on należy, ma niepustą część wspólną ze zbiorem X

Przykład 3 c.d.:

Obszar brzegowy zbioru $X=[1,25; 6;78]$ dla zbioru cech $P1$ i $P2$

$$Bn_{\tilde{P}_1}(X) = \widetilde{\overline{P_1}}X \setminus \widetilde{P_1}X = [1;7) \setminus [2;6) = [1;2) \cup [6;7)$$

$$Bn_{\tilde{P}_2}(X) = \widetilde{\overline{P_2}}X \setminus \widetilde{P_2}X = U \setminus \emptyset = U$$

Obszar pozytywny zbioru $X=[1,25; 6;78]$ dla zbioru cech $P1$ i $P2$

$$Pos_{\tilde{P}_1}(X) = \widetilde{P_1}X = [2;6)$$

$$Pos_{\tilde{P}_2}(X) = \widetilde{P_2}X = \emptyset$$

Obszar negatywny zbioru $X=[1,25; 6;78]$ dla zbioru cech $P1$ i $P2$

$$Neg_{\tilde{P}_1}(X) = U \setminus \widetilde{\overline{P_1}}X = U \setminus [1;7) = [0;1) \cup [7;10)$$

$$Neg_{\tilde{P}_2}(X) = U \setminus \widetilde{\overline{P_2}}X = U \setminus U = \emptyset$$

Przykład 3 c.d.:

Dokładność aproksymacji zbioru $X=[1,25; 6;78]$ dla zbioru cech $P1$ i $P2$

$$\mu_{\tilde{P}_1}(X_F) = \frac{\overline{\tilde{P}_1 X}}{\overline{\tilde{P}_1 X}} = \frac{4}{6} = \frac{2}{3}$$

$$\mu_{\tilde{P}_2}(X_N) = \frac{\overline{\tilde{P}_2 X}}{\overline{\tilde{P}_2 X}} = \frac{0}{10} = 0$$

Dokładność aproksymacji zbioru X dla zbioru cech $P2$ wynosi 0, co oznacza, że jest on całkowicie \tilde{P}_2 - niedefiniowalny.



Aproksymacja (przybliżenie) rodziny zbiorów

\tilde{P} - dolną aproksymacją rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ nazywamy zbiór $\underline{\tilde{P}}X$ opisany następująco:

$$\underline{\tilde{P}}X = \{\underline{\tilde{P}}X_1, \underline{\tilde{P}}X_2, \dots, \underline{\tilde{P}}X_n\}$$

UWAGA:

Dolną aproksymacją zbioru X jest więc zbiór dolnych aproksymacji zbiorów należących do zbioru X (rodziny zbiorów).

\tilde{P} - górną aproksymacją rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ nazywamy zbiór $\overline{\tilde{P}}X$ opisany następująco:

$$\overline{\tilde{P}}X = \{\overline{\tilde{P}}X_1, \overline{\tilde{P}}X_2, \dots, \overline{\tilde{P}}X_n\}$$

UWAGA:

Górną aproksymacją zbioru X jest więc zbiór górnych aproksymacji zbiorów należących do zbioru X (rodziny zbiorów).

Aproksymacja (przybliżenie) rodziny zbiorów

\tilde{P} - pozytywny obszar rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ definiujemy jako sumę pozytywnych obszarów zbiorów X_i , dla $i=1, \dots, n$

$$\text{Pos}_{\tilde{P}}(X) = \bigcup_{X_i \in X} \text{Pos}_{\tilde{P}}(X_i)$$

\tilde{P} - negatywny obszar rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ jest różnicą zbioru U i sumy negatywnych obszarów zbiorów X_i , dla $i=1, \dots, n$

$$\text{Neg}_{\tilde{P}}(X) = U \setminus \bigcup_{X_i \in X} \text{Neg}_{\tilde{P}}(X_i)$$

\tilde{P} - brzegowy obszar rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ definiujemy jako sumę obszarów brzegowych zbiorów X_i , dla $i=1, \dots, n$

$$\text{Bn}_{\tilde{P}}(X) = \bigcup_{X_i \in X} \text{Bn}_{\tilde{P}}(X_i)$$



Aproksymacja (przybliżenie) rodziny zbiorów

\tilde{P} - jakość aproksymacji rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ wyraża się wzorem

$$\gamma_{\tilde{P}}(X) = \frac{\overline{\overline{\text{Pos}_{\tilde{P}}(X)}}}{U}$$

\tilde{P} - dokładność aproksymacji rodziny zbiorów $X = \{X_1, X_2, \dots, X_n\}$, gdzie $X \subseteq U$ wyraża się wzorem

$$\beta_{\tilde{P}}(X) = \frac{\overline{\overline{\text{Pos}_{\tilde{P}}(X)}}}{\sum_{X_i \in X} \overline{\overline{\tilde{P}X_i}}}$$



Przykład 2 c.d.:

Rozważmy rodzinę zbiorów X , której elementami są trzy zbiory samochodów:

$$X_F = \{x_3, x_4, x_8\}, X_N = \{x_2, x_9, x_{10}\}, X_T = \{x_1, x_5, x_6, x_7\}$$

\tilde{C} -dolna aproksymacja rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\underline{\tilde{C}}X = \{\underline{\tilde{C}}X_F, \underline{\tilde{C}}X_N, \underline{\tilde{C}}X_T\} = \{\{x_3, x_8\}, \{x_2, x_9, x_{10}\}, \{x_1, x_6, x_7\}\}$$

\tilde{C} -górna aproksymacja rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\bar{\tilde{C}}X = \{\bar{\tilde{C}}X_F, \bar{\tilde{C}}X_N, \bar{\tilde{C}}X_T\} = \{\{x_3, x_4, x_5, x_8\}, \{x_2, x_9, x_{10}\}, \{x_1, x_4, x_5, x_6, x_7\}\}$$

Przykład 2 c.d.:

\tilde{C} -brzegowy obszar rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\text{Bn}_{\tilde{C}}(X) = \text{Bn}_{\tilde{C}}(X_F) \cup \text{Bn}_{\tilde{C}}(X_N) \cup \text{Bn}_{\tilde{C}}(X_T) = \{x_4, x_5\} \cup \emptyset \cup \{x_4, x_5\} = \{x_4, x_5\}$$

\tilde{C} -pozytywny obszar rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\begin{aligned} \text{Pos}_{\tilde{C}}(X) &= \text{Pos}_{\tilde{C}}(X_F) \cup \text{Pos}_{\tilde{C}}(X_N) \cup \text{Pos}_{\tilde{C}}(X_T) = \{x_3, x_8\} \cup \{x_2, x_9, x_{10}\} \cup \{x_1, x_6, x_7\} = \\ &= \{x_1, x_2, x_3, x_6, x_7, x_8, x_9, x_{10}\} \end{aligned}$$

\tilde{C} -negatywny obszar rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\begin{aligned} \text{Neg}_{\tilde{C}}(X) &= U \setminus (\text{Neg}_{\tilde{C}}(X_F) \cup \text{Neg}_{\tilde{C}}(X_N) \cup \text{Neg}_{\tilde{C}}(X_T)) = \\ &= U \setminus \{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_9, x_{10}\} = \emptyset \end{aligned}$$

Przykład 2 c.d.:

\tilde{C} - jakość aproksymacji rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\gamma_{\tilde{C}}(X) = \frac{\overline{\overline{\text{Pos}_{\tilde{C}}(X)}}}{\overline{U}} = \frac{8}{10}$$

\tilde{C} - dokładność aproksymacji rodziny zbiorów $X = \{X_F, X_N, X_T\}$:

$$\beta_{\tilde{C}}(X) = \frac{\overline{\overline{\text{Pos}_{\tilde{C}}(X)}}}{\sum_{X_i \in X} \overline{\overline{\tilde{C}X_i}}} = \frac{8}{4+3+5} = \frac{2}{3}$$



Analiza tablic decyzyjnych

Wykrycie zależności między cechami (atributami) systemu informacyjnego pozwala stwierdzać czy do jednoznacznego opisu obiektu należącego do zbioru U konieczna jest znajomość wartości wszystkich jego cech.

Stopień zależności zbioru atrybutów P_2 od zbioru atrybutów P_1 , gdzie $P_1, P_2 \subseteq Q$, jest określony następująco:

$$k = \gamma_{\tilde{P}_1}(P_2^*)$$

gdzie $\gamma_{\tilde{P}_1}$ oznacza jakość aproksymacji

UWAGA:

Zapis $P_1 \xrightarrow{k} P_2$ oznacza, że zbiór atrybutów P_2 zależy od atrybutów P_1 w stopniu $k < 1$, gdy $k = 1$, piszemy $P_1 \rightarrow P_2$

Analiza tablic decyzyjnych

Reguły tablicy decyzyjnej nazywamy **deterministycznymi**, jeżeli dla każdej pary reguł $R_a \neq R_b$ z równości wartości wszystkich atrybutów warunkowych C wynika równość wartości atrybutów decyzyjnych D , tzn.:

$$\forall_{\substack{R_a, R_b = 1, \dots, N \\ R_a \neq R_b}} : \forall_{c \in C} f_{R_a}(c) = f_{R_b}(c) \rightarrow \forall_{d \in D} f_{R_a}(d) = f_{R_b}(d)$$

Reguły tablicy decyzyjnej nazywamy **niedeterministycznymi**, jeżeli dla każdej pary reguł $R_a \neq R_b$ z równości wartości wszystkich atrybutów warunkowych C nie wynika równość wartości atrybutów decyzyjnych D , tzn.:

$$\exists_{\substack{R_a, R_b \\ R_a \neq R_b}} : \forall_{c \in C} f_{R_a}(c) = f_{R_b}(c) \rightarrow \exists_{d \in D} f_{R_a}(d) \neq f_{R_b}(d)$$

UWAGA:

Tablica decyzyjna jest **dobrze określona** jeśli jej wszystkie reguły są deterministyczne. W przeciwnym przypadku mówimy, że jest **źle określona**.

Analiza tablic decyzyjnych

Tablica decyzyjna posiadająca zbiór atrybutów warunkowych C oraz zbiór atrybutów decyzyjnych D jest **dobrze określona**, jeśli zbiór atrybutów decyzyjnych zależy od zbioru atrybutów warunkowych w stopniu równym 1 ($C \rightarrow D$), czyli

$$\gamma_{\tilde{P}1}(D^*)=1$$

UWAGA:

Źle określoną tablicę decyzyjną (tablicę zawierającą reguły niedeterministyczne) można przekształcić w tablicę dobrze określoną poprzez:

- usunięcie reguł niedeterministycznych
- rozszerzenie zbioru atrybutów warunkowych

Przykład 2 c.d.:

Zbadamy stopień zależności zbioru atrybutów warunkowych C od zbioru atrybutów decyzyjnych D

$$k = \gamma_{\tilde{C}}(D^*) = \frac{\overline{\text{Pos}_{\tilde{C}}(D^*)}}{\overline{U}}$$

Klasy abstrakcji relacji D-nierozróżnialności to zbiory X_F , X_N , X_T , zatem:

$$U/\tilde{D} = D^* = \{X_F, X_N, X_T\}$$

\tilde{C} -pozytywny obszar zbioru D^* :

$$\begin{aligned}\text{Pos}_{\tilde{C}}(D^*) &= \text{Pos}_{\tilde{C}}(X_F) \cup \text{Pos}_{\tilde{C}}(X_N) \cup \text{Pos}_{\tilde{C}}(X_T) = \{x_3, x_8\} \cup \{x_2, x_9, x_{10}\} \cup \{x_1, x_6, x_7\} = \\ &= \{x_1, x_2, x_3, x_6, x_7, x_8, x_9, x_{10}\}\end{aligned}$$

$$k = \gamma_{\tilde{C}}(D^*) = \frac{8}{10}$$

Stopień zależności zbioru atrybutów warunkowych C zależy od zbioru atrybutów decyzyjnych D w stopniu $k=0,8$, co zapisujemy

$$C \xrightarrow{0,8} D$$

Otrzymana wartość $k < 1$ oznacza, że tablica decyzyjna jest źle określona. Na podstawie zbioru atrybutów warunkowych nie można jednoznacznie wnioskować o przynależności obiektów przestrzeni U do poszczególnych zbiorów X_F , X_N , X_T , będących klasami abstrakcji relacji D-nierozróżnialności.

Przykład 2 c.d.:

Sposoby przekształcania tablicy decyzyjnej zawierającej reguły niedeterministyczne w tablicę dobrze określoną

- usuwanie reguł niedeterministycznych (reguły 4 i 5)

Reguła (R)	liczba drzwi ($c_1=q_1$)	moc silnika ($c_2=q_2$)	kolor ($c_3=q_3$)	marka ($d_1=q_4$)
1	2	60	niebieski	Toyota
2	2	100	czarny	Nissan
3	2	200	czarny	Ferrari
6	3	100	czerwony	Toyota
7	3	100	czerwony	Toyota
8	3	200	czarny	Ferrari
9	4	100	niebieski	Nissan
10	4	100	niebieski	Nissan

$$k=\gamma_{\tilde{C}}(D^*) = \frac{\overline{\overline{\{x_1, x_2, x_3, x_6, x_7, x_8, x_9, x_{10}\}}}}{\overline{\{x_1, x_2, x_3, x_6, x_7, x_8, x_9, x_{10}\}}} = \frac{8}{8} = 1 \quad - \text{ tablica jest dobrze określona}$$



Przykład 2 c.d.:

- rozszerzenie zbioru atrybutów warunkowych
(dodajemy kolejne atrybuty np.: c_4 - tapicerka, c_5 - felgi)

Reguła (R)	liczba drzwi (c_1)	moc silnika (c_2)	kolor (c_3)	tapicerka (c_4)	felgi (c_5)	marka (d_1)
1	2	60	niebieski	tkanina	stal	Toyota
2	2	100	czarny	tkanina	stal	Nissan
3	2	200	czarny	skóra	Al	Ferrari
4	2	200	czerwony	skóra	Al	Ferrari
5	2	200	czerwony	tkanina	stal	Toyota
6	3	100	czerwony	skóra	stal	Toyota
7	3	100	czerwony	tkanina	stal	Toyota
8	3	200	czarny	skóra	Al	Ferrari
9	4	100	niebieski	tkanina	stal	Nissan
10	4	100	niebieski	tkanina	Al	Nissan



Przykład 2 c.d.:

Nowy zbiór atrybutów warunkowych $C' = \{c_1, c_2, c_3, c_4, c_5\}$

Dziedziny atrybutów:

$V_{c_1} = \{2, 3, 4\}$, $V_{c_2} = \{60, 100, 200\}$, $V_{c_3} = \{\text{czarny, niebieski, czerwony}\}$,
 $V_{c_4} = \{\text{tkanina, skóra}\}$, $V_{c_5} = \{\text{stal, Al}\}$, $V_{d_1} = \{\text{Ferrari, Nissan, Toyota}\}$

Klasy abstrakcji relacji C' -nierozróżnialności \tilde{C}' określonej przez zbiór cech C' to zbiory jednoelementowe, ponieważ każdy element przestrzeni U ma przynajmniej jedną różną wartość cechy

Zbiór ilorazowy:

$$U/\tilde{C}' = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}, \{x_9\}, \{x_{10}\}\}$$

Obszar pozytywny zbiorów X_F , X_N , X_T :

$$\begin{aligned}\text{Pos}_{\tilde{C}'}(X_F) &= \tilde{C}'X_F = \{x_3, x_4, x_8\} = X_F \\ \text{Pos}_{\tilde{C}'}(X_N) &= \tilde{C}'X_N = \{x_2, x_9, x_{10}\} = X_N \\ \text{Pos}_{\tilde{C}'}(X_T) &= \tilde{C}'X_T = \{x_1, x_5, x_6, x_7\} = X_T\end{aligned}$$

Przykład 2 c.d.:

Górne aproksymacje zbiorów X_F , X_N , X_T :

$$\tilde{\tilde{C}}'X_F = \{x_3\} \cup \{x_5\} \cup \{x_8\} = \{x_3, x_4, x_8\} = X_F$$

$$\tilde{\tilde{C}}'X_N = \{x_2\} \cup \{x_9\} \cup \{x_{10}\} = \{x_2, x_9, x_{10}\} = X_N$$

$$\tilde{\tilde{C}}'X_T = \{x_1\} \cup \{x_5\} \cup \{x_6\} \cup \{x_7\} = \{x_1, x_5, x_6, x_7\} = X_T$$

\tilde{C}' -pozytywny obszar rodziny zbiorów D^* :

$$\begin{aligned}\text{Pos}_{\tilde{C}'}(D^*) &= \{x_3, x_4, x_8\} \cup \{x_2, x_9, x_{10}\} \cup \{x_1, x_5, x_6, x_7\} = \\ &= \{x_1, x_2, x_3, x_4, x_5, x_6, x_7, x_9, x_{10}\} = U\end{aligned}$$

\tilde{C}' - jakość aproksymacji rodziny zbiorów D^* :

$$\gamma_{\tilde{C}'}(D^*) = \overline{\overline{\text{Pos}_{\tilde{C}'}(D^*)}} / \overline{U} = \frac{10}{10} = 1$$

\tilde{C}' - dokładność aproksymacji rodziny zbiorów D^* :

$$\beta_{\tilde{C}'}(D^*) = \overline{\overline{\overline{\text{Pos}_{\tilde{C}'}(D^*)}}} / \sum_{X_i \in D^*} \overline{\overline{\tilde{C}'X_i}} = \frac{\overline{U}}{\overline{U}} = \frac{10}{10} = 1$$

Obie wartości wynoszą 1, rozszerzona tablica decyzyjna jest zatem dobrze określona.

Analiza tablic decyzyjnych c.d.

Zbiór atrybutów $P1 \subseteq Q$, jest **niezależny** w danym systemie informacyjnym, jeżeli dla każdego $P2 \subset P1$ zachodzi $\widetilde{P1} \neq \widetilde{P2}$. W przeciwnym przypadku zbiór $P1$ jest zależny

Zbiór atrybutów $P1 \subseteq Q$, jest **niezależny** ze względu na zbiór atrybutów $P2 \subseteq Q$ ($P2$ -niezależny), jeśli dla każdego $P3 \subset P1$ zachodzi $\widetilde{P1} \neq \widetilde{P2}$.

$$\text{Pos}_{\widetilde{P1}}(P2^*) \neq \text{Pos}_{\widetilde{P3}}(P2^*)$$

W przeciwnym przypadku zbiór $P1$ jest $P2$ -**zależny**

Analiza tablic decyzyjnych c.d.

Reduktem zbioru atrybutów $P_1 \subseteq Q$ nazywamy każdy niezależny zbiór $P_2 \subset P_1$, dla którego $\widetilde{P}_2 = \widetilde{P}_1$

Reduktem względnym zbioru atrybutów $P_1 \subseteq Q$ ze względu na P_2 (tzw. P_2 -reduktem) nazywamy każdy P_2 -niezależny zbiór $P_3 \subset P_1$, dla którego $\widetilde{P}_3 = \widetilde{P}_1$

Atrybut $p \in P_1$ jest **nieusuwalny** ze zbioru P_1 , jeżeli dla $P_2 = P_1 \setminus \{p\}$ zachodzi $\widetilde{P}_2 \neq \widetilde{P}_1$. W przeciwnym przypadku atrybut p jest **zbędny**.

Zbiór wszystkich atrybutów nieusuwalnych ze zbioru P nazywa się **rdzeniem** P , co zapisujemy następująco:

$$\text{CORE}(P) = \{p \in P: \widetilde{P}' \neq \widetilde{P}, P' = P \setminus \{p\}\}$$



Analiza tablic decyzyjnych c.d.

Znormalizowany współczynnik istotności podzbioru zbioru atrybutów warunkowych $C' \subseteq C$ ma postać

$$\sigma_{(C,D)}(C') = \frac{\gamma_{\tilde{C}}(D^*) - \gamma_{\tilde{C}''}(D^*)}{\gamma_{\tilde{C}}(D^*)}$$

gdzie $C'' = C \setminus C'$

UWAGA:

Wartość zerowa znormalizowanego współczynnika istotności otrzymana dla danego podzbioru atrybutów warunkowych C wskazuje, że podzbiór ten może być usunięty ze zbioru atrybutów warunkowych bez szkody dla aproksymacji rodziny zbiorów D^*

Dowolny podzbiór atrybutów warunkowych $C' \subseteq C$ nazywamy przybliżonym D-reduktem zbioru atrybutów C , a **błąd przybliżenia** tego reduktu wyznaczamy ze wzoru:

$$\varepsilon_{(C,D)}(C') = \frac{\gamma_{\tilde{C}}(D^*) - \gamma_{\tilde{C}'}(D^*)}{\gamma_{\tilde{C}}(D^*)}$$

Przykład 2 c.d.:

Rozszerzony zbiór atrybutów warunkowych $C' = \{c_1, c_2, c_3, c_4, c_5\}$

Przykładowe podzbiory zbioru C' :

$C1 = \{c_1, c_3, c_4, c_5\}$, $C2 = \{c_1, c_2, c_3\}$, $C3 = \{c_1, c_2\}$, $C4 = \{c_1, c_3\}$, $C5 = \{c_2, c_3\}$,
 $C6 = \{c_1\}$, $C7 = \{c_2\}$, $C8 = \{c_3\}$

- Zbiór C' jest zbiorem zależnym, ponieważ podzbiór $C1 \subset C'$ generuje takie same klasy abstrakcji jak C'

Zbiory ilorazowe:

$$U/\widetilde{C'} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}, \{x_9\}, \{x_{10}\}\}$$

$$U/\widetilde{C1} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}, \{x_9\}, \{x_{10}\}\}$$

- Zbiór $C2$ jest zbiorem niezależnym, ponieważ wszystkie podzbiory różne od $C2$ generują inne niż dla $C2$ klasy abstrakcji

Zbiory ilorazowe:

$$U/\widetilde{C2} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4, x_5\}, \{x_6, x_7\}, \{x_8\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C3} = \{\{x_1\}, \{x_2\}, \{x_3, x_4, x_5\}, \{x_6, x_7\}, \{x_8\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C4} = \{\{x_1\}, \{x_2, x_3\}, \{x_4, x_5\}, \{x_6, x_7\}, \{x_8\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C5} = \{\{x_1\}, \{x_2\}, \{x_3, x_8\}, \{x_4, x_5\}, \{x_6, x_7\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C6} = \{\{x_1, x_2, x_3, x_4, x_5\}, \{x_6, x_7, x_8\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C7} = \{\{x_1\}, \{x_2, x_6, x_7, x_9, x_{10}\}, \{x_3, x_4, x_5, x_8\}\}$$

$$U/\widetilde{C8} = \{\{x_1, x_9, x_{10}\}, \{x_2, x_3, x_8\}, \{x_4, x_5, x_6, x_7\}\}$$

Przykład 2 c.d.:

Rozszerzony zbiór atrybutów warunkowych $C' = \{c_1, c_2, c_3, c_4, c_5\}$

Przykładowe podzbiory zbioru $C1 = \{c_1, c_3, c_4, c_5\}$:

$C9 = \{c_1, c_3, c_4\}$, $C4 = \{c_1, c_3\}$, $C6 = \{c_1\}$, $C7 = \{c_2\}$, $C8 = \{c_3\}$,

- Zbiór C' jest zbiorem zależnym, ponieważ podzbiór $C1 \subset C'$ generuje takie same klasy abstrakcji jak C'

Zbiory ilorazowe:

$$U/\widetilde{C'} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}, \{x_9\}, \{x_{10}\}\}$$

$$U/\widetilde{C1} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}, \{x_9\}, \{x_{10}\}\}$$

- Zbiór $C1$ jest zbiorem niezależnym, ponieważ wszystkie podzbiory różne od $C1$ generują inne niż dla $C1$ klasy abstrakcji

Zbiory ilorazowe:

$$U/\widetilde{C4} = \{\{x_1\}, \{x_2, x_3\}, \{x_4, x_5\}, \{x_6, x_7\}, \{x_8\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C6} = \{\{x_1, x_2, x_3, x_4, x_5\}, \{x_6, x_7, x_8\}, \{x_9, x_{10}\}\}$$

$$U/\widetilde{C7} = \{\{x_1\}, \{x_2, x_6, x_7, x_9, x_{10}\}, \{x_3, x_4, x_5, x_8\}\}$$

$$U/\widetilde{C8} = \{\{x_1, x_9, x_{10}\}, \{x_2, x_3, x_8\}, \{x_4, x_5, x_6, x_7\}\}$$

$$U/\widetilde{C9} = \{\{x_1\}, \{x_2\}, \{x_3\}, \{x_4\}, \{x_5\}, \{x_6\}, \{x_7\}, \{x_8\}, \{x_9, x_{10}\}\}$$

(UWAGA: Sprawdzić klasy abstrakcji dla pozostałych podzbiorów zbioru $C1$!!!)

Przykład 2 c.d.:

Rozszerzony zbiór atrybutów warunkowych $C' = \{c_1, c_2, c_3, c_4, c_5\}$

- Zbiór $C_1 = \{c_1, c_3, c_4, c_5\} \subset C'$ jest reduktem zbioru C' , ponieważ generuje takie same klasy abstrakcji jak zbiór C' i jest zbiorem niezależnym
- Atrybut c_2 jest zbędny ponieważ $C_1 = C' \setminus \{c_2\}$ oraz $U/\tilde{C}' = U/\tilde{C}_1$
- Rdzeniem zbioru C' są atrybuty $\{c_1, c_3, c_4, c_5\}$ tzn.:

$$\text{CORE}(C') = \{c_1, c_3, c_4, c_5\}$$

- Jakość aproksymacji rodziny zbiorów D^* ze względu na zbiór cech C_1 (\tilde{C}_1 -jakość):

$$\gamma_{\tilde{C}_1}(D^*) = \overline{\text{Pos}_{\tilde{C}_1}(D^*)} / \overline{U} = \frac{10}{10} = 1$$

- Współczynnik istotności podzbioru $\{c_2\}$ zbioru atrybutów warunkowych C

$$\sigma_{(C', D)}(\{c_2\}) = (\gamma_{\tilde{C}}(D^*) - \gamma_{\tilde{C}_1}(D^*)) / \gamma_{\tilde{C}}(D^*) = (1 - 1) / 1 = 0$$

Wartość 0 oznacza, że atrybut c_2 jest nieistotny, jego usunięcie nie wpłynie zatem na jakość aproksymacji rodziny zbiorów D^* . Ponadto dla wyjściowego zbioru reguł warunkowych C , błąd przybliżenia wynosi 0,2